



Geopolitics Terrarium

～神の地政学とバタフライ・エフェクト～

実世界地図上の国家 AI たちに「介入者」として介入し、資源・金融の連鎖反応
(5 商品に集計された巨視的需給) が世界をどう変えるかを観測する非対称安全保障サンドボックス

テーゼ: 全国家安全保障シミュレーター — 相互防衛・安全保障ジレンマ・核抑止・霧を備えた
176 カ国 AI 世界で、危機安定性を意思決定層と抑止構成の交換で測る。

問い: ①AI 意思決定者は危機の安定性を変えるか ②抑止は AI 相手でも機能するか —
危機を固定し、意思決定層 (ルール/学習/思考 AI) と核保有構成だけを交換して、
決定論シミュレーション×A/B 反実仮想で純粋に帰属する。
介入点分析 (海峡封鎖/金融感染/技術創発/偽情報) はそのための測定基盤

複合戦略 AI: LLM (戦略層・z.ai GLM) × 強化学習 (戦術層・自己対戦) × ルール (世界解決層)

第 2 回 AI エージェント社会シミュレーション・ハッカソン「メタ安全保障」応募作品

み (ど) Discord ID: mu_sette

問題提起: 3つの賭け → 1つの表現



LLM は「教師」になれる

人間の政策直観を LLM が言語化し、RL へ蒸留。1 回数十秒の思考が 80KB・CPU 即時の重みになり、全 176 カ国に配備される。(→ 6. 学習 AI: 蒸留と転移)



世界は「実験装置」になる

現実で考えるべき世界をモデル化すれば、核危機も海峡封鎖も同じ条件で何度でも再現できる。訓練にも A/B 測定にも使え、有意なデータが取れるかもしれない。(→ 4. パタフライ・エフェクト)



因子が増えるほど、仮説が検証できる

核・核傘・輸出規制・通貨ブロック…因子と介入の語彙を増やすほど、「ここを動かせば世界はこう変わる」という**因果の仮説**が検証可能になる。AI は因子を観測して反応し、連鎖は parent リンクで追跡できる。(→ 5. 因果カスケード)

「事後推論ではなく、介入実験で因果を測る」

決定論シミュレーション × A/B 反実仮想 × 因果グラフ — 安全保障テーマで実験

① **実装:** 教師=glm-5.3 (実 API 呼び出し監査済み) → hold-out 一致率 89.7%

② **実装:** bit 等価の決定論 — 176 カ国×72 ヶ月・安定性は 10seed×3 抑止構成

③ **実装:** 因子 4 種・介入 12 カード・全イベントに parent リンク


1. コンセプト: 介入者は統治しない、介入だけする

非対称設計

- プレイヤー（介入者）は国家を運営しない — 介入カードと環境スライダーで世界を歪めるだけ
- 国家 AI が生存をかけた対応を行い、プレイヤーは結果の連鎖を読む
- 介入カード: 海峡封鎖・資源の創造/消滅・技術の授与/禁止・利上げ・救済・災害・偽情報・好戦性の書き換え

再現性ファースト

- 完全決定論: 同じ (seed, preset, policy, scenario) → bit 等価 (テスト担保)
- 全イベントは因果 parent リンク付き JSONL → 介入から崩壊・開戦への因果グラフを再構築
- リプレイはログ再生のみで再現 (LLM 再呼び出し不要)



ライブ介入 UI 「介入モード」（国家選択で介入カードが出現）

2. アーキテクチャ: 複合戦略 AI × イベントソーシング

層	担当	実装
戦略層	外交・軍事姿勢・配給判断、 自然言語の理屈	LLM (z.ai GLM、OpenAI 互換)
戦術層	毎月の予算配分・姿勢・配給	強化学習 (numpy Actor-Critic、自己対戦)
世界解決層	市場・物理・財政・連鎖	決定論ルールエンジン

1 tick (介入モード=1 時間、実験=1 ヶ月。実時間校正) のパイプライン
時計緩和 → 予約消化 (動員・参戦) → 技術 → 生産 → 貿易 (比例配給・海峡スロットル) → 市場 → 消費 → **意思決定 (AI、週次)** → 外交 → 紛争 → 財政・マクロ

安全保障パラメータ拡張 (v5) : 政府の異質性

- 思想ベクトル: 危機許容度・軍事偏重・修正主義・報復性・同盟遵守度が国ごとに異なる (軍事偏重は実軍事費比率から導出)
- 核態勢 counterforce/MAD/NFU が抑止係数を変える $\times 0.75/1.0/\times 1.25$
- リチャードソン軍拡・交渉による講和 (Fearon 型)・軍備管理条約・内戦ハザード・核拡散連鎖
- 思想は RL 観測 (41→48 次元)・LLM プロンプト・報酬に反映 — 同じ状況でも政府の性質が戦術を変える

実時間校正: 介入は即時に効かない

- 価格発見 $\tau \approx 36h$ (期待ショックは数時間で載る) / 航路封鎖の実効化 $\tau \approx 10$ 日 (航行中の船はまだ着く)
- 戦争は動員 **4-30 日を経てのみ勃発** (mobilization → war_start、緊張消退で stand_down) / 同盟参戦は 1 日-1 週の協議後
- GDP は年率複利・失業は $\tau \approx 4$ ヶ月・政府の意思決定は週次 — ホルムズ封鎖は「3 日で価格、3 週間で輸送、3 ヶ月で不足と破綻、その先で戦争」

経済の相互接続 (連鎖的物理)

- 半導体ファブは電力と地下資源を消費 → エネルギー不足はファブ減産 ($\times 0.4$) へ伝播
- 宇宙資源は**海峡封鎖を無視** (軌道直通) し、喪失は軍事力漸減 ($-1.5/月$) へ
- 輸入依存×価格上昇 → インフレ → 債務国の金利上昇 (金融連鎖への入口)



リプレイビューア: 実世界地図・航路・価格・イベントカスケード

3. 世界モデル: 実地図 × 資源 × 未来技術の創発

実世界の再現（公開データのみ）

- ▶ Natural Earth GeoJSON（パブリックドメイン）で実地図描画、16 の実在世界主体
- ▶ 実在 7 海峡（ホルムズ・マラッカ・台湾・スエズ・パプ・エル・マンデブ・パナマ・トルコ）を航路が経由
- ▶ 債務対 GDP 比は実態を概算反映（日 252%・米 122%・エジプト 93%…）
- ▶ シードから**架空世界を実地図上に自動生成**（需給バランス保証、8 アーキタイプ）

介入で資源を創造できる

- ▶ 地下資源（レアアース）・宇宙資源（軌道）を含む 6 種の資源ユニット
- ▶ `create_resource` / `destroy_resource` で介入が需給構造そのものを書き換え

3 層の深化: 同定・表現力・検証

- ▶ **層 1 同定:** 1990 湾岸危機の油価形状（PRICE_TAU 24h/REOPEN_TAU 90 日。ピーク×2.39=実績×2.3）+ **2008 年失業率経路にオークン則 τ** （半減期 9 ヶ月）+ **1973-74 年 CPI にパススルー**（+4.66pt=実績+4.8）。来歴表 A/B/C
- ▶ **層 2 表現力:** 政体（WGI 発言権 2024 実データで民主 40/混合 64/専制 72）、選挙と政権交代、民主的平和、専制の抑圧、**戦争の強度**（限定→総力戦、人的被害 146 万人 @基準、崩壊は専制に集中）
- ▶ **層 3 検証:** 3 エピソードのバッテリー（1990 較正+1973/1979 独立検証） — 方向と GDP 影響は全て一致、価格振幅は大ショックで 30-50% 下振れ（系統的限界として記録）。**予算の慣性**・制裁の経済的歯・**国**戦争誘因も追加

未来技術の創発（2026 年開始、超加速研究世界）

分類	技術（創発時期）	効果
兵器	自律ドローン群(t8)・極超音速迎撃網(t22)	軍事力増強・不信上昇
製造	AI 設計ファブ(t10)・自己修復工場(t26)	生産倍率向上
資源	核融合(t20) ・宇宙太陽光(t24)・小惑星採掘(t30)	油田ゼロの国にも電力
宗教	AI 神格宗教(t15) ・テクノ・ナショナリズム(t18)	安定↑・他国との信頼↓

導入確率は研究吸収能力（GDP・金融・半導体備蓄）に比例 → 技術格差が創発的に生成。介入で `grant_tech` / `ban_tech` で技術ツリー自体を介入できる。

4. バタフライ・エフェクト（実測）：介入点 × 指標の感度

シナリオ（seed=42・同世界・36tick・実ログ）	世界 GDP	エネルギー価格	半導体価格	デフォルト	不足
baseline（無介入）	184.1	1.00	1.00	1	312
台湾海峡封鎖	164.2（-10.8%）	—	1.04	2	—
ホルムズ海峡封鎖	150.7（-18.1%）	1.31	1.08	2	477
三重危機（ホルムズ+台湾+スエズ）	130.2（-29.3%）	1.15	1.09	2	—
金融危機（封鎖+世界金利+8%）	127.4（-30.8%）	1.26	1.08	4	—
金融危機 + 日・エジプト救済（A/B）	131.5（-28.6%）	1.26	1.08	3	—


発見 1: 物理より金融が重い

金融感染（GDP -30.8%・デフォルト 4 件）は海峡封鎖より GDP に深く効き、**破綻の連鎖**という質的に異なる被害を生む。安全保障における金融の位置づけを可視化。

発見 2: 封鎖はスタグフレーションを起こす

ホルムズ封鎖はエネルギー価格 **1.31** と同時に平均失業率 **6.7%→7.1%** を押し上げ。同じ封鎖履歴で核融合だけを禁止すると CO2 累積 **+3.1%** — 技術創発は気候経路も変える。

5. 因果カスケード: 介入 1 件から連鎖を辿る



金融危機シナリオのカスケード図（横軸=時間、レーン=イベント区分、青矢印=親リンク。紫=介入・橙=価格・赤=破綻）

デフォルト感染チェーン（実ログ earth_earth_financial_crisis）

tick	出来事	因果（親リンク/文脈）
t6	介入: ホルムズ海峡封鎖	同 tick に energy ×2.38・chips ×1.49 の価格急騰
t10	介入: 世界金利 +8%	全債務国の利払い急増
t18	日本が破綻（利率 28%）	封鎖+利上げの複合圧力(旧ログのため親リンク未記録)
t18	EU・サウジ・米国が日本債で損失	親=日本の破綻（credibility_hit — 感染）
t32	日本が再破綻（利率 30%）	感染による信用毀損+債務再蓄積

図の設計: 親リンクが記録された連鎖は青矢印で因果の方向を示し、親を持たない主要イベントも時刻どおりに配置する（親リンクの欠落だけで連鎖の全体像が消えない）。介入→子孫イベント数の定量比較は analysis/out/cascade_bar_*.png 。

読み方: t6 の封鎖直後に経済レーンへ価格急騰・航路スロットル（小点の群れ）が立ち上がり、利上げ t10 を挟んで金融レーンの破綻 t18 → 感染（同 tick）→ 再破綻 t32 へと、連鎖が下のレーンへ落ちていく様子が読める。

6. 学習 AI: LLM→RL 蒸留と全 176 カ国転移

LLM→RL 蒸留パイプライン (rl/distill.py・v9～v12 実測)

- 1. 収集: glm-5.3 政府の (観測 61 次元→決定) を 167 回の実 API 呼び出し+拡充で計 1,056 サンプル (フォールバック監査済み)
- 2. 蒸留: 一致率 **89.7%**・macro-F1 **0.709**・稀クラス recall 0.79/0.50/1.00 — 模倣は観測の情報量で **0.71 に飽和** (線形プローブ 0.669=深さの利得なし)
- 3. 微調整の限界 (スケール知見) : 9.5k params では有効、12.7M では KL アンカー $\beta \leq 30$ でも教師一致が崩壊 (RLHF 流オフセットは **Adam のスケール不変性で無効**)
- 4. 配備の正体 (v12 訂正) : 配備成功 (崩壊 8 カ国) は教師一致率 1.5% の「福祉+配給」一律方策 — A2C が発見した生存マクロであり**模倣と生存は別目的** (忠実な模倣は崩壊 42)

LLM の戦略判断を 80KB・CPU 即時の重みに圧縮して全 176 カ国へ配備。旧配備 run の沈黙的フォールバック (heuristic と同一出力) を検出・再計測した (失敗の記録 #7)。

転移評価: 訓練に無い 176 カ国世界・ホルムズ 72 ヶ月 (v10 再計測)

指標	heuristic	earth 専修	lh (GAE+DR)	+fine 行動
世界 GDP	121.6	121.2	120.3	122.0
平均失業率	5.35%	5.65%	5.51%	4.50%
平均債務	104%	132%	108%	99%
崩壊	23	12	10	43 (悪化)

知見: 微操作 (fine) は失業で有利だが分布シフト下で崩壊 3 倍 (43)。GAE(λ)+訓練地平 96 ヶ月+ドメインランダム化 (lh) が汎用配備の最適 — 要件間のトレードオフ自体を測定した。

両義性 (正直な結果)

全力国学習 AI 化は崩壊を 23→**10 カ国**に半減し安定+3.7pt 改善する一方、GDP-1.1%・債務+4pt — **安定を買って成長を若干売る**。拡散抑止下では戦争 89.4→**26.1 件** — AI の効果は**文脈依存**である。

7. LLM 戦略層: 国家 AI の思考はログに残る

- ・ 各国家は persona（技術立島国・資源専制国…）を持ち、情勢 JSON（自国状態・技術・他国関係）から政策 JSON（外交・軍事姿勢・配給・予算）を返す
- ・ 判断の**自然言語の理屈 (rationale)** がイベントログに記録され、リプレイで「なぜその国家がその行動を取ったか」を追跡できる
- ・ 失敗時は heuristic ヘフォールバック、生応答はログ保存 — **再現性を壊さない**
- ・ 安定性実験（実 API 検証済み・24 ヶ月）：戦争 20 件・初回開戦 **t7**（ルール AI t4）・核保有国が当事者の戦争ゼロ — 思考 AI は危機の起点を遅らせる

ハイブリッド実走行の思考 (LLM 戦略 × RL 戦術)

- 「半導体を交渉カードにエネルギー供給源を分散確保。備蓄最優先の防衛態勢」 (LLM 戦略)
- × 予算=stockpile (RL 戦術)

フル LLM 実行 (リッチ観測+因子ドクトリン、16 カ国 GLM、14tick)

- t8 欧州連合** (defensive)
エネルギー 100% 輸入依存が存亡リスク。RUS・SAU と貿易協定で供給確保し備蓄最優先。防衛態勢維持。
- t7 中国** (neutral)
ホルムズ封鎖で備蓄最優先。食料(BRA)・エネルギー(SAU)・半導体(TWN)供給線を貿易協定で固め依存を逆転させる
- t8 ロシア** (neutral)
ホルムズ混乱とエネ高騰を好機に、エネ・穀物を切望する TUR・EGY・IND と貿易協定で収益と影響力を最大化
- t5 韓国** (defensive)
半導体覇権を後盾に米同盟で核抑止。エネルギー・食料備蓄最優先、防御固める
- t11 トルコ** (defensive)
エネルギー備蓄枯渇が存亡問題。価格高騰前に備蓄を最大化し、露との貿易協定で供給を確保
- t13 イラン** (defensive)
食料備蓄枯渇が最大の存亡脅威。高騰するエネルギー輸出で外貨を稼ぎ中印と貿易、危機まで核は保留。

224 件の政策判断・同盟 17 件形成。日本は t7 にデフォルト。**イランは「核開発で抑止力確保」→「危機まで核は保留」**ヘドクトリン転換、サウジは「IRN 核開発に対抗し抑止確保」と相手の因子を観測して反応 — リッチ観測 (トレンド・海峡曝露・他国の核) を読んだ戦略が創発する。

8. まとめ: どの介入点が連鎖を変えるか

介入点	観測された連鎖	教訓
海峡封鎖（物理）	エネルギー+31% → ファブ電力不足 → 半導体+8% → GDP -18.1%・失業+0.4pt	1 点の介入が複数商品に伝播
世界金利（金融）	債務国の利払い急増 → 破綻 → 債権国へ感染（credibility_hit）	金融感染は封鎖と異なる被害構造
ペイルアウト（金融介入）	破綻 4 件→3 件（A/B で計測）	最後の貸し手の効果が定量できる
技術の禁止/授与（創発）	核融合禁止で CO2 累積+3.1%・日本の破綻が t21→t34 に遅延	未来技術が地政学依存をリセット
IF 史: 過去の介入差し替え	t6 で日本救済→日本の破綻は防げずも、EU・米国への感染連鎖が消失（GDP +26.3・破綻 4→2）	救済の効果は件数でなく感染経路の遮断
全世界 176 カ国で同一実験	ホルムズ封鎖(18 ヶ月)でも主要国は破綻せず債務+7pt/インフレで吸収（自国通貨建て校正）。破綻は外貨建て新興国に集中。交渉講和 1,820 件が創発	規模効果: 財政感染は途上国に集中。学習 AI 政府は危機対応で債務規律を学習
IF: イラン核保有	混沌世界（戦争 10 件）で t1 に核授与→戦争 0 件・GDP+4.0%（日本の破綻は新発生）	核抑止は軍事経路のみ効き、金融は独立
Q1+Q2: AI×抑止の安定性	10seed×72 ヶ月固定危機で 核なし 306 件 → 現状 150 件 → 拡散 89 件。拡散下の学習 AI は 26 件・初回開戦 t15→t37 へ遅延	抑止は標的選択を変え、学習 AI は抑止構造が強いほど安定化に寄与（核保有国が当事者の戦争は全構成でゼロ）
100 年シミュレーション（2126 年）	ルール AI 世界: GDP 117→15.5 兆（-87%）・核 9→35 カ国・イデオロギー二極化。学習 AI 世界: 崩壊 26 と内政は良いが GDP 5.5 兆・破綻 3,476 回でより深く没落	AI 政府は危機の「分散」を変えられるが世紀スケールの複合ストレスの「停止」は不可能 — 変えられるのは制度設計だけ
RL 報酬設計（AI）	予算ドクトリンは変わるが構造的危機は不変	階層が違う介入は代替できない

貢献: (1) 決定論×イベントソーシングによる因果が追跡できる安全保障サンドボックス、(2) LLM×RL×ルールの複合戦略 AI と自己対戦学習、(3) 介入点ごとの感度行列と A/B 反実仮想による「どこを動かせば何が変わるか」の定量示唆、(4) 介入モードというリアルタイム介入 UI、(5) コミット済みログから make_figures.py で全図表が一括再生できる再現性。

△ 本シミュレーションは公開されている概算データに基づく中立・分析目的のものです。特定の国・個人の標的化を意図するものではありません。地図データは Natural Earth（パブリックドメイン）を使用しています。